# ProyectoM1 — Análisis de clientes y restaurantes (Miami)

Prueba integradora del Módulo 1 · Pasos y resultados · Octubre 2026

# 1. Descripción del proyecto

El proyecto analiza una base de 30.000 clientes de restaurantes de EE.UU. y la cruza con la oferta gastronómica de Miami obtenida de la API de Yelp. El objetivo es entender el perfil del cliente de Miami y proponer una segmentación accionable (ver Recomendaciones.pdf).

# 2. Estructura del repositorio

| Ruta | Contenido |
|---|---|
| Avances/Notebooks/1_EDA.ipynb | Carga, exploración, filtrado por ciudad, limpieza y tablas de distribución |
| Avances/Notebooks/2_API_Yelp.ipynb | Obtención de restaurantes de Miami vía API de Yelp Fusion y su análisis |
| Avances/Notebooks/3_WebScraping.ipynb | Técnica de web scraping con requests + BeautifulSoup |
| Datasets/ | CSV originales y derivados generados por los notebooks |
| Documentacion/README.pdf | Este documento: pasos y resultados |
| Documentacion/Recomendaciones.pdf | Propuestas de segmentación de clientes |

# 3. Pasos realizados

## 3.1 EDA — carga y exploración (1_EDA.ipynb)

- Carga de **base_datos_restaurantes_USA_v2.csv**: 30.000 filas × 17 columnas; sin filas duplicadas ni IDs repetidos.
- Diagnóstico de calidad: ~50% de clientes sin teléfono/correo; nulos en edad (101), gasto (145) y preferencias (1.403); edades imposibles (-5 a 300) y frecuencias negativas; teléfonos en 5+ formatos distintos.

## 3.2 Filtrado por ciudad: Miami

- Se eligió Miami porque el dataset de Yelp cubre exclusivamente esa ciudad, lo que permite cruzar ambas fuentes.
- Resultado: **3.186 clientes** (10,6% de la base), guardados en Datasets/clientes_miami.csv.

## 3.3 Limpieza de datos

- Valores imposibles (28 edades fuera de rango, 173 frecuencias negativas) convertidos a nulo e imputados con la **mediana**, robusta frente a outliers.
- Nulos categóricos etiquetados ('No especificado' / 'Sin dato'): los datos personales no se inventan.
- Teléfonos normalizados al formato XXX-XXX-XXXX (manejo de prefijos +1/001 y extensiones); verificación final: 0 sin normalizar y 0 nulos en el dataset.
- Resultado: Datasets/clientes_miami_limpio.csv — 3.186 clientes completos, edades 18-80.

### 3.4 Tablas de distribución

- Tablas de frecuencia (cantidad y %) de género, estrato, preferencias, membresía y tipo de pago; variables numéricas agrupadas en rangos; tablas cruzadas (gasto por estrato, premium por género, gasto por edad).

### 3.5 API de Yelp (2_API_Yelp.ipynb)

- Código de extracción del endpoint /v3/businesses/search documentado y reproducible (requiere API Key); el notebook funciona sin clave usando la extracción guardada.
- 463 filas que corresponden a **200 restaurantes únicos** (una fila por categoría gastronómica); deduplicación por id.
- **Integración oferta-demanda**: cruce de las preferencias alimenticias de los clientes con las categorías de Yelp, y del estrato socioeconómico con el nivel de precio de los restaurantes.

### 3.6 Web scraping (3_WebScraping.ipynb)

- Demostración completa de la técnica sobre books.toscrape.com (sitio de práctica): extracción de 100 registros, limpieza del precio con regex y exportación a CSV, con pautas éticas (robots.txt, pausas entre peticiones).

## 4. Resultados principales

- El cliente de Miami supera el promedio nacional en gasto por comida (**$39,8 vs $32,6**), frecuencia de visita (4,4 vs 3,9 al mes) e ingresos ($6.476 vs $5.390).
- El **estrato socioeconómico** es la variable que más separa el gasto: Muy Alto $68,6 — Alto $40,1 — Medio $25,0 — Bajo $13,3. La edad, en cambio, casi no influye (~$38-41 en todos los rangos).
- Perfil del mercado: 61,5% de estratos Alto/Muy Alto, 53,2% con membresía premium, preferencia dominante por **mariscos** (25,7%).
- Oferta (Yelp): calificaciones concentradas arriba — **82% con rating > 4.0** (media 4.34); nivel de precio más común: Medio.
- Pagos: efectivo 38,3%, tarjeta 32,3%, app 27,4%; criptomoneda marginal (2%).
- Integración oferta-demanda: los **mariscos** están bien cubiertos (25,7% de demanda vs 16,5% de oferta), pero hay una **brecha vegetariana/vegana** (34,8% de demanda combinada vs 5,5% de oferta) y **déficit de oferta premium** (61,5% de clientes de estrato Alto/Muy Alto vs 17,7% de restaurantes de precio alto).

## 5. Cómo reproducir

- Crear un entorno virtual con Python 3.14 e instalar: pandas, requests, beautifulsoup4, jupyter.
- Ejecutar los notebooks en orden (1 → 2 → 3) desde la carpeta Avances/Notebooks; las rutas a los datos son relativas (../../Datasets/).
- 2_API_Yelp.ipynb corre sin credenciales; definir la variable de entorno YELP_API_KEY solo si se desea re-extraer desde la API.