ProyectoM1 — Análisis de clientes y restaurantes (Miami)

Prueba integradora del Módulo 1 · Pasos y resultados · Octubre 2026

1. Descripción del proyecto

El proyecto analiza una base de 30.000 clientes de restaurantes de EE.UU., la cruza con la oferta gastronómica de Miami obtenida de la API de Yelp y visualiza los patrones de gasto, preferencias y membresías. El objetivo es entender el perfil del cliente de Miami y proponer una segmentación accionable (ver Recomendaciones.pdf).

2. Estructura del repositorio

Ruta	Contenido
Avances/Notebooks/1_EDA.ipynb	Carga, exploración, filtrado por ciudad, limpieza y tablas de distribución
Avances/Notebooks/2_API_Yelp.ipynb	Obtención de restaurantes de Miami vía API de Yelp Fusion e integración con los clientes
Avances/Notebooks/3_graficos.ipynb	Visualizaciones: ciudades, estratos, gasto, preferencias, membresías y consumo de licor
Avances/Notebooks/3_WebScraping.ipynb	Técnica de web scraping con requests + BeautifulSoup
Avances/Notebooks/4_Scraping_Wikipedia.ipynb	Cultura de Miami desde Wikipedia (script generado con IA) + pasos extra con Selenium
Datasets/	CSV originales y derivados generados por los notebooks
Documentacion/README.pdf	Este documento: pasos y resultados
Documentacion/Recomendaciones.pdf	Propuestas de segmentación de clientes

3. Pasos realizados

3.1 EDA — carga y exploración (1_EDA.ipynb)

- Carga de **base_datos_restaurantes_USA_v2.csv**: 30.000 filas × 17 columnas; sin filas duplicadas ni IDs repetidos.
- Diagnóstico de calidad: ~50% de clientes sin teléfono/correo; nulos en edad (101), gasto (145) y preferencias (1.403); edades imposibles (-5 a 300) y frecuencias negativas; teléfonos en 5+ formatos distintos.

3.2 Filtrado por ciudad: Miami

- Se eligió **Miami** como ciudad de análisis por ser uno de los principales mercados gastronómicos y turísticos de EE.UU.; los datos de restaurantes de esa ciudad se obtienen luego desde la API de Yelp (2_API_Yelp.ipynb), lo que permite cruzar ambas fuentes.
- Resultado: **3.186 clientes** (10,6% de la base), guardados en Datasets/clientes_miami.csv.

3.3 Limpieza de datos

- Valores imposibles (28 edades fuera de rango, 173 frecuencias negativas) convertidos a nulo e imputados con la **mediana**, robusta frente a outliers.
- Nulos categóricos etiquetados ('No especificado' / 'Sin dato'): los datos personales no se inventan.
- Teléfonos normalizados al formato XXX-XXX-XXXX (manejo de prefijos +1/001 y extensiones); verificación final: 0 sin normalizar y 0 nulos en el dataset.

- Resultado: Datasets/clientes_miami_limpio.csv — 3.186 clientes completos, edades 18-80.

3.4 Tablas de distribución

- Tablas de frecuencia (cantidad y %) de género, estrato, preferencias, membresía, tipo de pago, consumo de licor y ocio; variables numéricas agrupadas en rangos; tablas cruzadas (gasto por estrato, premium por género, gasto por edad).

3.5 API de Yelp (2_API_Yelp.ipynb)

- Código de extracción del endpoint /v3/businesses/search documentado y reproducible (requiere API Key); el notebook funciona sin clave usando la extracción guardada.
- 463 filas que corresponden a **200 restaurantes únicos** (una fila por categoría gastronómica); deduplicación por id.
- **Integración oferta-demanda**: cruce de las preferencias alimenticias de los clientes con las categorías de Yelp, y del estrato socioeconómico con el nivel de precio de los restaurantes.

3.6 Visualizaciones (3_graficos.ipynb)

- Sobre la **base completa** de 30.000 clientes (misma limpieza que 1_EDA): barras de clientes por ciudad, listado de estratos, gasto promedio mensual por ciudad (gasto por comida × visitas al mes), frecuencia vs gasto por estrato, dispersión ingresos-gasto, preferencias alimenticias por ciudad, perfil del top 10% de gasto, membresías por ciudad y consumo de licor por edad.

3.7 Web scraping (3_WebScraping.ipynb)

- Demostración completa de la técnica sobre books.toscrape.com (sitio de práctica): extracción de 100 registros, limpieza del precio con regex y exportación a CSV, con pautas éticas (robots.txt, pausas entre peticiones).

3.8 Scraping de Wikipedia con IA + Selenium (4_Scraping_Wikipedia.ipynb)

- Script **generado con inteligencia artificial (Claude, Anthropic)** a partir de las consignas, revisado y ejecutado como parte del proyecto.
- Scraping con requests + BeautifulSoup de la sección **Cultura** del artículo de Miami en Wikipedia en español: 14 párrafos de 3 subsecciones (artes escénicas, música popular, medios), guardados en Datasets/cultura_miami.csv.
- **Pasos extra con Selenium** (Edge headless), verificados por código y documentados con capturas: acceso al artículo de Miami → búsqueda de Chicago con el buscador interno → color del sitio cambiado a **Oscuro** (clase skin-theme-clientpref-night verificada) → idioma cambiado a **inglés** (URL en.wikipedia.org y lang='en' verificados).

4. Resultados principales

- El cliente de Miami supera el promedio nacional en gasto por comida (**$39,8 vs $32,6**), frecuencia de visita (4,4 vs 3,9 al mes) e ingresos ($6.476 vs $5.390). **Miami es además la ciudad donde más se gasta al mes** ($222 de promedio vs $127 de Houston, la menor).
- El **estrato socioeconómico** es la variable que más separa el gasto: Muy Alto $68,6 — Alto $40,1 — Medio $25,0 — Bajo $13,3 por comida (en Miami). A nivel nacional, el gasto mensual va de $19 (Bajo) a $470 (Muy Alto) y la correlación ingresos-gasto es **0,70**. La edad, en cambio, casi no influye (~$38-41 en todos los rangos).
- El **top 10% de gasto** (≥ $412/mes) gasta en promedio $678/mes y es 94,8% de estrato Muy Alto; no come distinto del resto: visita el doble (7,7 vs 3,9 veces/mes) y paga el triple por comida ($89 vs $26).
- Perfil del mercado de Miami: 61,5% de estratos Alto/Muy Alto, 53,2% con membresía premium (la mayor adopción del país; Chicago lidera en cantidad con 2.215), preferencia dominante por **mariscos** (25,7%) — única ciudad donde no ganan las carnes.

- Oferta (Yelp): calificaciones concentradas arriba — **82% con rating > 4.0** (media 4.34); nivel de precio más común: Medio.
- Pagos: efectivo 38,3%, tarjeta 32,3%, app 27,4%; criptomoneda marginal (2%). Consumo de licor: 90,4% en el rango 18-30, contra 50-57% en los demás rangos de edad.
- Integración oferta-demanda: los **mariscos** están bien cubiertos (25,7% de demanda vs 16,5% de oferta), pero hay una **brecha vegetariana/vegana** (34,8% de demanda combinada vs 5,5% de oferta) y **déficit de oferta premium** (61,5% de clientes de estrato Alto/Muy Alto vs 17,7% de restaurantes de precio alto).

5. Cómo reproducir

- Crear un entorno virtual con Python 3.14 e instalar: pandas, numpy, matplotlib, requests, beautifulsoup4, selenium, jupyter (Selenium usa Microsoft Edge y descarga el driver automáticamente).
- Ejecutar los notebooks en orden (1_EDA → 2_API_Yelp → 3_graficos → 3_WebScraping → 4_Scraping_Wikipedia) desde la carpeta Avances/Notebooks; las rutas a los datos son relativas (../../Datasets/).
- 2_API_Yelp.ipynb corre sin credenciales usando la extracción guardada. Para re-extraer desde la API, poner REEXTRAER = True: la clave de entrenamiento provista por el curso se incluye en yelp_api_key.txt (raíz del repositorio), o puede definirse la variable de entorno YELP_API_KEY.